

Mașini autonome. Detectia și recunoașterea semnelor de circulație.

Luca Sebastian
Grupa 1308A

Ganea Luiza-Andreea
Grupa 1308A

Abstract—Sistemul de recunoaștere a semnelor de circulație ajută utilizatorul să identifice automat semnalele de trafic. Astăzi, creșterea numărului de vehicule în trafic a dus la creșterea numărului de drumuri și semne de circulație. Drept urmare, șoferii au de învățat noi semne de circulație și trebuie să acorde o atenție deosebită acestora în timpul condusului. O ușoară neglijență din partea șoferului poate duce la consecințe majore. Sistemul de recunoaștere a semnelor de circulație poate fi utilizat în intersecții aglomerate. Sistemul de recunoaștere a traficului alertează și informează automat șoferul despre semnul de circulație identificat. Acest sistem este special conceput pentru a ajuta persoanele cu deficiențe de vedere să fie conștienți de semnele de circulație întâlnite, iar persoanele daltoniste să identifice culorile acestora, datorită transformărilor de ajustare a luminozității și a contrastului aplicate imaginilor interceptate. Sistemul de recunoaștere a semnelor de circulație analizează schema de culori pentru a recunoaște și înțelege ce semne diferite se află în împrejurimile mașinii. Această tehnologie este utilă și în contextul unor condiții meteorologice nefavorabile conducerii unui autovehicul, spre exemplu ceață, lumină solară prea puternică sau întuneric.

I. DESCRIEREA TEMEI

O mașină autonomă este un vehicul capabil să opereze (să participe la trafic) fără implicarea unui șofer. Acestea nu au nevoie de prezența unui pasager uman pentru a prelua controlul.

Mașinile autonome se bazează pe senzori, elemente de acționare, procesoare și algoritmi puternici și complecși pentru a executa software-ul. Semnele de circulație au caracteristici distincte, care pot fi utilizate pentru detectarea și identificarea lor într-un timp cât mai scurt și cu o acuratețe cât se poate de mare.

În cadrul acestui proiect am implementat un sistem de detectare și recunoaștere a semnelor de circulație în timp real. Platforma de dezvoltare este Nvidia Jetson Nano Developer Kit, placă de dezvoltare ce rulează un sistem de operare bazat pe Linux. Pentru feed-ul video live vom folosi o cameră web conectată direct la Jetson. Această tehnologie oferă o mai bună securitate deoarece mașinile ce rulează pe sistemul de operare Linux.

Majoritatea oamenilor petrec foarte mult timp atât în trafic (aglomerație), cât și conducând ore întregi, fie pentru locul de muncă, fie pentru alte activități. Scopul nostru este de a îmbunătăți siguranța șoferului și confortul acestuia.

Semnele de circulație sunt detectate prin analiza informațiilor de culoare conținute în imagini. Semnele detectate sunt apoi clasificate în funcție de caracteristicile lor de

formă, precum triunghi, pătrat și forme circulare. Vom antrena un program bazat pe inteligență artificială cu un set de imagini pentru fiecare semn în parte, pentru a obține o precizie cât mai mare. Vom folosi programul pentru a analiza în timp real informațiile transmise de camera web.

II. STATE-OF-THE-ART & RELATED WORK

A. Traffic Sign Detection and Recognition using Image Processing

<https://www.ijert.org/traffic-sign-detection-and-recognition-using-image-processing>

B. Traffic sign recognition application based on image processing techniques

<https://www.sciencedirect.com/science/article/pii/S1474667016416009>

C. Image processing based traffic sign detection and recognition with fuzzy integral

<https://ieeexplore.ieee.org/document/7502715>

D. TRAFFIC SIGN RECOGNITION USING IMAGE PROCESSING

<http://troindia.in/journal/ijcesr/vol5iss4part12/7-11.pdf>

E. Application of Machine Learning in Traffic Sign Detection and Fine-grained Classification

<https://medium.com/@alibaba-cloud/application-of-machine-learning-in-traffic-sign-detection-and-fine-grained-classification-9ea33f0375d1>

F. Traffic Sign Detection Recognition

<https://medium.com/lifeandtech/traffic-sign-detection-recognition-f6e741543619>

III. SOLUȚII COMERCIALE

A. BOSCH: Road sign information for heavy commercial vehicles

<https://www.bosch-mobility-solutions.com/en/solutions/assistance-systems/road-sign-information-cv/>

B. Sygic: Traffic Sign recognition

<https://www.sygic.com/what-is/sign-recognition>



Fig. 1. Trecere de pietoni



Fig. 2. Stop




Fig. 3. Drum cu prioritate



Fig. 4. Stație de încărcare pentru mașini electrice



Fig. 5. Semafor

IV.

V. DESCRIEREA METODEI

Etape parcurse:

- Instalarea unui sistem de operare Linux Ubuntu pe plăcuța de dezvoltare. Jetson Nano Developer Kit poate fi utilizat pentru dezvoltarea de sisteme pentru robotică, drone, analiză video, gestionarea traficului cu detectarea vehiculelor și a persoanelor, clasificarea imaginilor, detectarea obiectelor, segmentarea și procesarea vorbirii.
- Instalarea docker-ului oferit de Nvidia, care conține programul Python pentru achiziționarea și prelucrarea imaginilor dorite.
- Testarea funcționalităților prin rularea exemplarelor oferite de Nvidia.
- Testarea modului "camera-capture" care permite achiziția și clasificarea imaginilor în funcție de câteva clase definite anterior de către utilizator.
- Data Augmentation: Crearea algoritmului de multiplicare a numărului de imagini folosind limbajul Python. Am utilizat biblioteca open-source PIL (Python Imaging Library), special concepută pentru manipularea imaginilor. Asupra fiecărei fotografii am aplicat următoarele operații, în această ordine: Transformare (toate imaginile trebuie să aibă formatul .jpg pentru a putea fi utilizate), Redimensionare (unele din imaginile folosite aveau o dimensiune mult prea mare pentru nevoile noastre, așa că le-am adus la o lățime maximă de 800 pixeli), Modificare contrast (am exportat o imagine cu un contrast de două ori mai mic și un cu un contrast de două ori mai mare) și Rotire (am exportat o imagine rotită la stânga cu 10 grade și una rotită la dreapta tot cu 10 grade). Astfel, putem mări setul de date cu 500%. În cazul nostru, asta a însemnat o creștere de la 300 de imagini, la aproape 1500.
- Dobândirea unui set larg de date personalizat (crearea unei colecții de scene de trafic: imagini ce includ semnele de circulație Trecere de pietoni, Stop, Drum cu prioritate, Semafor și Stație de încărcare pentru mașini electrice). Acest set de date este mărit cu ajutorul unui algoritmul de multiplicare prezentat mai sus.
- Antrenarea AI-ului cu setul de date prin metoda Try and Error cu grade de încredere, formând rețele neuronale puternice capabile să comunice rapid.
- Testarea programului cu ajutorul imaginilor obținute în urma aplicării algoritmului de multiplicare. Detectarea indicatoarelor rutiere se va face în timp real, utilizând o cameră web ce va fi conectată la placa de dezvoltare Nvidia Jetson Nano Developer Kit.
- La întâlnirea semnelor de circulație "Stop", șoferul mașinii va fi atenționat de către aceasta că este obligat să încetinească și să oprească în dreptul semnelor de stop în orice situație, indiferent dacă pe drumul prioritar se află sau nu alți participanți la trafic. Acesta își poate continua deplasarea dacă nu este nevoie să ofere prioritate altor participanți la trafic.




Fig. 6. Nvidia Jetson Nano Developer Kit




Fig. 7. Identificare

- Indicatorul rutier "Drum cu prioritate" este instalat la începutul unui drum cu prioritate sau înaintea intersecțiilor cu un drum fără prioritate. În aceste situații, mașina va indica șoferului că acesta nu trebuie să ofere prioritate altor vehicule deoarece acesta are prioritate în intersecția în care urmează să pătrundă. Șoferul își poate continua drumul respectând însă regulile condusului preventiv.
- La întâlnirea semnului de circulație "Stație de încărcare" pentru mașini electrice, mașina va atenționa șoferul numai în cazul în care aceasta are nevoie de realimentare cu energie electrică.
- La întâlnirea indicatorului "Trecere de pietoni", șoferul va fi atenționat de obligativitatea încetinirii autovehiculului într-un interval de viteză prevăzut de lege. În cazul în care pe trecerea de pietoni sau în împrejurimile acesteia se află persoane, șoferul va trebuie să oprească și să aștepte ca toți pietonii să traverseze.
- Indicatoarele rutiere de tip "Semafor" sunt amplasate la o distanță de 200m înaintea unui semafor, în zone în care se consideră că existența lor este necesară și ar putea lua prin surprindere participanții la trafic. Mașina va avertiza șoferul de prezența unui semafor, pentru ca ulterior, acesta să fie capabil să observe și să interpreteze semnificația culorii pe care i-o indică semaforul întâlnit.

VI. REZULTATE

Cu ajutorul containerului oferit de Nvidia, ce conține un program Python care achiziționează și prelucrează imaginile, am antrenat o rețea neuronală. Astfel, într-o primă etapă, utilizându-ne de imaginile captate cu camera web, am putut face o clasificare a feed-ului video live în două clase: "Background" și "Charger". Pentru antrenare am folosit aproximativ 100 de imagini pentru fiecare clasă în parte. Ulterior, pentru a ajunge către scopul final al proiectului, acela de a recunoaște semnele de circulație, am creat un set de date personalizat pentru fiecare clasă. Momentan, clasele care pot fi identificate și clasificate sunt: "Stop", "Trecere", "Ev"(Indicator încărcător pentru mașini electrice), "Semafor", "Prioritate" și "Back-




Fig. 8. Clasificare

ground"(care indică absența unui indicator atunci când folosim clasificarea imaginilor). Pentru fiecare clasă am pornit cu un set de aproximativ 50 de imagini, dar cu ajutorul algoritmului de "Data augmentation" realizat în Python, am avut o creștere de 500% a setului de date, ajungând astfel la aproape 1500 de imagini. Pentru a spori precizia clasificării și a indentificării, AI-ul a analizat întregul set de date de 10 ori (10 epochs). Din cauza limitării hardware a plăcuței Jetson Nano 2GB, aceste sesiuni de antrenare au putut dura chiar și o oră.

VII. CONCLUZII

- În cazul operației de Clasificare, am obținut o medie de recunoaștere de aproximativ 50%. Deși numărul de imagini cu care s-a realizat antrenarea rețelei neuronale a fost destul de mare, nu a fost suficient pentru a obține o acuratețe precisă.
- În cazul operației de Identificare, am obținut o medie de recunoaștere de aproximativ 60%, puțin mai bună decât la Clasificare, dar puțin sub așteptările noastre.

VIII. OBSERVAȚII

- Cu toate că am folosit imagini diversificate, împreună cu algoritmul pentru Data Augmentation, nu au fost

suficiente ca număr pentru a permite algoritmului să recunoască semnele de circulație în toate condițiile de trafic. Ca urmare, antrenarea cu un set mult mai diversificat ar spori precizia clasificării și a identificării substanțial.

TABLE I
ALOCAREA TASK-URILOR

Task ID	Descriere task	Membru echipă
task1	documentație	Sebastian, Luiza
task2	antrenarea AI-ului	Sebastian, Luiza
task3	implementarea codului pentru clasificarea imaginilor	Sebastian, Luiza
task4	implementarea codului pentru identificarea imaginilor	Sebastian, Luiza
task5	implementarea algoritmului de multiplicare	Sebastian
task6	testarea produsului	Sebastian, Luiza

REFERENCES

- [1] Everything You Need to Know About Self-Driving Cars in 2022. By: SafeRoadsUSA
- [2] C. Fang, S. Chen, and C. Fuh, "Road-sign detection and tracking," IEEE Trans. on Vehicular Technology, vol. 52, pp. 1329-1341, 2003.
- [3] <https://github.com/dusty-nv/jetson-inference>
- [4] Klym Yamkovyi, Proofread by Nadiia Pyvovar, Cherepanov Oleksandr, "Object Detection on NVIDIA Jetson TX2T.
- [5] <https://www.nvidia.com/en-us/training/online/>
- [6] <https://developer.nvidia.com/embedded/learn/getting-started-jetson>
- [7] M. Young, The Technical Writer's Handbook. Mill Valley, CA: University Science, 1989.
- [8] C. Liu, F. Chang, Z. Chen and D. Liu, "Fast Traffic Sign Recognition via High-Contrast Region Extraction and Extended Sparse Representation", IEEE Transactions on Intelligent Transportation Systems, Vol. 17, January 2016.
- [9] J. N. Chourasia and P. Bajaj, "Centroid Based Detection Algorithm for Hybrid Traffic Sign Recognition System", Emerging Trends in Engineering and Technology (ICETET), 2010 3rd International Conference on, pp. 96-100, Goa, November 2010.
- [10] Wahyono, L. Kurniangugoro, and K.H. Jo, "Traffic Sign Recognition and Tracking for a Vision-based Autonomous Vehicle Using Optimally Selected Features", SICE Annual Conference 2015, pp. 1419-1422, Hangzhou, July 2015.
- [11] K. Fu, I.Y.H. Gu and A. Ödöblom, "Traffic Sign Recognition using Salient Region Features: A Novel Learning-based Coarse-to-Fine Scheme", Intelligent Vehicles Symposium (IV), 2015 IEEE, pp. 443- 448, Seoul, 2015.
- [12] S. Kim and S. Kwon, "Improvement of traffic sign recognition by accurate ROI refinement", 15th International Conference on Control, Automation and Systems (ICCAS 2015), pp. 926-928, Korea, October 2015.
- [13] M. Boumediene, J.P. Lauffenburger, J. Daniel and C. Cudel, "Coupled Detection, Association and Tracking for Traffic Sign Recognition", Intelligent Vehicles Sy
- [14] Q. Wang, C. Zheng, H. Yu and D. Deng, "Integration of Heterogeneous Classifiers Based on Choquet Fuzzy Integral ", 2015 7th International Conference on Intelligent Human-Machine Systems and Cybernetics, pp. 543-547, 2015.
- [15] M. Karakose and K. FÖrÖldak, "A Shadow Detection Approach Based on Fuzzy Logic Using Images Obtained from PV Array", Modeling, Simulation, and Applied Optimization (ICMSAO), 2015 6th International Conference on, pp. 1-5, 2015.

- [16] G. Karaduman, M. Karakose and E. Akin, "Experimental Fuzzy Diagnosis Algorithm Based on Image Processing for Rail Profile Measurement", MECHATRONKA, 2012 15th International Symposium, pp. 1-6, 2012.
- [17] M. Karakose and K. FÖrÖldak C. Tastimur, E. Akin, M. Karakose and I. Aydin, "Detection of Rail Faults Using Morphological Feature Extraction Based Image Processing ", Signal Processing and Communications Applications Conference (SIU), 2015 23th, pp. 1244-1247, 2015
- [18] Deval Shah, "The Essential Guide to Data Augmentation in Deep Learning"
- [19] Connor Shorten & Taghi M. Khoshgoftaar, "A survey on Image Data Augmentation for Deep Learning", 06 July 2019
- Great Learning Team, "Understanding Data Augmentation. What is Data Augmentation & how it works?", Oct 31, 2022
- Jessica Shea Choksey and Christian Wardlaw, "Levels of Autonomous Driving, Explained", May 05, 2021
- George Dimitrakopoulos, Elias Panagiotopoulos, in Autonomous Vehicles, "A path of structural transformation for the automotive and insurance industries toward autonomous vehicles", 2021