

# Mașini autonome. Detectția și recunoașterea semnelor de circulație.

Luca Sebastian  
Grupa 1308A

Ganea Luiza-Andreea  
Grupa 1308A

**Abstract**—Sistemul de recunoaștere a semnelor de circulație ajută utilizatorul să identifice automat semnalele de trafic. Astăzi, creșterea numărului de vehicule în trafic a dus la creșterea numărului de drumuri și semne de circulație. Drept urmare, șoferii au de învățat noi semne de circulație și trebuie să acorde o atenție deosebită acestora în timpul condusului. O ușoară neglijență din partea șoferului poate duce la consecințe majore. Sistemul de recunoaștere a semnelor de circulație poate fi utilizat în intersecții aglomerate. Sistemul de recunoaștere a traficului alertează și informează automat șoferul despre semnul de circulație identificat. Acest sistem este special conceput pentru a ajuta persoanele cu deficiențe de vedere să fie conștienți de semnele de circulație întâlnite, iar persoanele daltoniste să identifice culorile acestora. Sistemul de recunoaștere a semnelor de circulație analizează schema de culori pentru a recunoaște și înțelege ce semne diferite se află în împrejurimile mașinii.

## I. DESCRIEREA TEMEI

O mașină autonomă este un vehicul capabil să opereze fără implicarea unui șofer. Acestea nu au nevoie de prezența unui pasager uman pentru a prelua controlul.

Mașinile autonome se bazează pe senzori, elemente de acționare, procesoare și algoritmi puternici și complecși pentru a executa software-ul. Semnele de circulație au caracteristici distincte, care pot fi utilizate pentru detectarea și identificarea lor într-un timp cât mai scurt și cu o acuratețe cât se poate de mare.

Ne propunem ca în acest proiect să implementăm un sistem de detectare și recunoaștere a semnelor de circulație în timp real. Platforma de dezvoltare este Nvidia Jetson Nano Developer Kit, placă de dezvoltare ce rulează un sistem de operare bazat pe Linux. Pentru feed-ul video live vom folosi o cameră web conectată direct la Jetson.

Scopul nostru este de a îmbunătăți siguranța șoferului și confortul acestuia.

Semnele de circulație sunt detectate prin analizarea informațiilor de culoare conținute în imagini. Semnele detectate sunt apoi clasificate în funcție de caracteristicile lor de formă, precum triunghi, pătrat și forme circulare. Combinarea informațiilor de culoare și formă a semnelor de circulație e clasificată în una din următoarele categorii: pericol, informație, obligație sau interdicție. Vom antrena un program bazat pe inteligență artificială cu un set de imagini pentru fiecare semn în parte, pentru a obține o precizie cât mai mare. Vom folosi programul pentru a analiza în timp real informațiile transmise de camera web.




Fig. 1. Nvidia Jetson Nano Developer Kit




Fig. 2. Algorithm

## II. STATE-OF-THE-ART & RELATED WORK

### A. Traffic Sign Detection and Recognition using Image Processing

<https://www.ijert.org/traffic-sign-detection-and-recognition-using-image-processing>

### B. Traffic sign recognition application based on image processing techniques

<https://www.sciencedirect.com/science/article/pii/S1474667016416009>

### C. Image processing based traffic sign detection and recognition with fuzzy integral

<https://ieeexplore.ieee.org/document/7502715>

### D. TRAFFIC SIGN RECOGNITION USING IMAGE PROCESSING

<http://troindia.in/journal/ijcesr/vol5iss4part12/7-11.pdf>

### E. Application of Machine Learning in Traffic Sign Detection and Fine-grained Classification

<https://medium.com/@alibaba-cloud/application-of-machine-learning-in-traffic-sign-detection-and-fine-grained-classification-9ea33f0375d1>

### F. Traffic Sign Detection Recognition

<https://medium.com/lifeandtech/traffic-sign-detection-recognition-f6e741543619>

## III. SOLUȚII COMERCIALE

### A. BOSCH: Road sign information for heavy commercial vehicles

<https://www.bosch-mobility-solutions.com/en/solutions/assistance-systems/road-sign-information-cv/>

### B. Sygic: Traffic Sign recognition

<https://www.sygic.com/what-is/sign-recognition>

## IV. DESCRIEREA METODEI

Câteva dintre etapele parcurse sunt:

- Inițializarea plăcii de dezvoltare
- Implementarea codului sursă pe noua platformă de dezvoltare
- Dobândirea unui set de date personalizat (Crearea unei colecții de scene de trafic realizate de către cameră)
- Antrenarea AI-ului cu setul de date
- Testarea programului într-o situație reală (Cu ajutorul unei machete, vom simula o situație reală de trafic, care să reproducă la scară semne de circulație în diferite condiții și poziționări. Detectarea semnelor se va face cu camera web conectată la Jetson).
- La întâlnirea semnelui Stop, mașina va încetini automat și se va opri în dreptul semnelui de stop, rămânând datorită șoferului să se asigure că poate continua traseul.
- La întâlnirea semnelui de parcare, mașina va căuta automat un loc de parcare liber și va indica șoferului poziția acestuia, după care se va opri, pentru ca șoferul să efectueze manevra de parcare.
- La întâlnirea semnelui Stație de încărcare pentru mașini electrice, mașina va atenționa șoferul, asta numai dacă mașina are nevoie de realimentare cu energie electrică.
- La întâlnirea semnelui Trecere de pietoni, mașina va încetini. În caz că există persoane care traversează sau care se apropie de trecere, mașina va opri automat.

## V. REZULTATE INTERMEDIARE

Cu ajutorul containerului oferit de Nvidia, ce conține un program Python care achiziționează și prelucrează imaginile, am antrenat o rețea neuronală. Aceasta poate detecta și distinge indicatoarele din imaginile captate. Ulterior, acestea sunt clasificate în două categorii: "background" și "charger". Pentru fiecare clasă am folosit în jur de 100 de imagini, un număr destul de mic, dar care pentru nevoile noastre s-a dovedit a fi suficient. Setul de date a fost prelucrat de 10 ori (10 epochs) pentru a spori precizia clasificării.



Fig. 3. Trecere de pietoni



Fig. 4. Stop



Fig. 5. Parcare



Fig. 6. Stație de încărcare pentru mașini electrice




Fig. 7. Semafor

## VI. CONCLUZII

- Pentru clasa "background" am atins o precizie medie de 62%, iar la clasa "charger", 99%.
- Din cauza setului mic de date, precizia este foarte mult influențată de factori externi, în special nivelul de luminosități din încăperea. Această problemă va fi rezolvată antrenând programul cu un set mai mare și mai variat de date.
- Ne dorim să obținem o acuratețe de minim 80% pentru detectarea și recunoașterea semnelor de circulație

TABLE I  
ALOCAREA TASK-URILOR

Task ID	Descriere task	Membru echipă
task1	documentație	Sebastian, Luiza
task2	antrenarea AI-ului	Sebastian, Luiza
task3	implementarea codului sursă pentru clasificarea imaginilor	Sebastian, Luiza
task5	testarea produsului	Sebastian, Luiza

## REFERENCES

- [1] Everything You Need to Know About Self-Driving Cars in 2022. By: SafeRoadsUSA
- [2] C. Fang, S. Chen, and C. Fuh, "Road-sign detection and tracking," IEEE Trans. on Vehicular Technology, vol. 52, pp. 1329-1341, 2003.
- [3] <https://github.com/dusty-nv/jetson-inference>
- [4] Klym Yamkovyi, Proofread by Nadiia Pyvovar, Cherepanov Oleksandr, "Object Detection on NVIDIA Jetson TX2T."
- [5] <https://www.nvidia.com/en-us/training/online/>
- [6] <https://developer.nvidia.com/embedded/learn/getting-started-jetson>
- [7] M. Young, The Technical Writer's Handbook. Mill Valley, CA: University Science, 1989.
- [8] C. Liu, F. Chang, Z. Chen and D. Liu, "Fast Traffic Sign Recognition via High-Contrast Region Extraction and Extended Sparse Representation", IEEE Transactions on Intelligent Transportation Systems, Vol. 17, January 2016.
- [9] J. N. Chourasia and P. Bajaj, "Centroid Based Detection Algorithm for Hybrid Traffic Sign Recognition System", Emerging Trends in Engineering and Technology (ICETET), 2010 3rd International Conference on, pp. 96-100, Goa, November 2010.
- [10] Wahyono, L. Kurniaggoro, and K.H. Jo, "Traffic Sign Recognition and Tracking for a Vision-based Autonomous Vehicle Using Optimally Selected Features", SICE Annual Conference 2015, pp. 1419-1422, Hangzhou, July 2015.
- [11] K. Fu, I.Y.H. Gu and A. Ödöblom, "Traffic Sign Recognition using Salient Region Features: A Novel Learning-based Coarse-to-Fine Scheme", Intelligent Vehicles Symposium (IV), 2015 IEEE, pp. 443- 448, Seoul, 2015.
- [12] S. Kim and S. Kwon, "Improvement of traffic sign recognition by accurate ROI refinement", 15th International Conference on Control, Automation and Systems (ICCAS 2015), pp. 926-928, Korea, October 2015.
- [13] M. Boumediene, J.P. Lauffenburger, J. Daniel and C. Cudel, "Coupled Detection, Association and Tracking for Traffic Sign Recognition", Intelligent Vehicles Sy
- [14] Q. Wang, C. Zheng, H. Yu and D. Deng, "Integration of Heterogeneous Classifiers Based on Choquet Fuzzy Integral ", 2015 7th International Conference on Intelligent Human-Machine Systems and Cybernetics, pp. 543-547, 2015.
- [15] M. Karakose and K. FÖrÖldak, "A Shadow Detection Approach Based on Fuzzy Logic Using Images Obtained from PV Array", Modeling, Simulation, and Applied Optimization (ICMSAO), 2015 6th International Conference on, pp. 1-5, 2015.
- [16] G. Karaduman, M. Karakose and E. Akin, "Experimental Fuzzy Diagnosis Algorithm Based on Image Processing for Rail Profile Measurement", MECHATRONIKA, 2012 15th International Symposium, pp. 1-6, 2012.
- [17] M. Karakose and K. FÖrÖldak
- [18] C. Tastimur, E. Akin, M. Karakose and I. Aydin, "Detection of Rail Faults Using Morphological Feature Extraction Based Image Processing ", Signal Processing and Communications Applications Conference (SIU), 2015 23th, pp. 1244-1247, 2015